

Klausur Data Literacy, WS 2019/20, Ersttermin: Gedächtnisprotokoll

- Umgang mit Missing Values: 4 Methoden aufzählen, 1 ausführlich erläutern
- Bsp. für Randomized Setup gegeben: Was ist Unabhängige, was abhängige Variable? Wie könnte Selection Bias auftreten?
- Informationen sammeln: Optimale Anzahl von Messungen auf einer Waage um eine ungleiche unter 12 Kugeln zu finden? Erkläre.
- Balkendiagramm, Scatterplot: Welche visuellen Variablen verwendet? Welche vis. Variablen sind gut/schlecht für Ordinale Daten (1 pro Kategorie)
- PCA: Für (U, a_{ni}, b_i) ist $MSE = \dots$ gegeben $\rightarrow$ minimiere und löse nach a_{ni}, b_i auf
- Vergleiche PCA vs LDA: Welche Annahmen über (Co-)Varianz, was wird untersucht, wird zwischen abhängigen und unabhängigen Variablen unterschieden? (True / False)
- 8 abhängige Variablen erhoben $\rightarrow$ Welche Visualisierung ist gut zur Erkennung von Kovarianzen? Ist diese Skalierbar (bzgl. der Anzahl an Variablen)?
- Ranking als Ziel im Gegensatz zu Klassifizierung/Regression. Was ist die Idee von graphen-basiertem Ranking, was die computationale Herausforderung dabei?
- Z-Skalierte Daten: Was ist eine sinnvolle Anwendung, was die Unit of Measurement der skalierten Daten, was ein Passendes Color Scheme?
- Für Vergleich zweier Clustering-Methoden: Welche Visualisierung? (Schematische Illustration)
- UpSet Plot für 5 konkrete Beispiele erstellen (Überlappungen)